Instituto Politécnico de Viana do Castelo

LICENCIATURA EM ENGENHARIA INFORMÁTICA

OPÇÃO II – APRENDIZAGEM ORGANIZACIONAL / SISTEMAS DE SUPORTE À DECISÃO

Data Science - Visualização de Dados usando SCRIPTS em PYTHON

29447- Ivo Ramoa

ivoramoa@ipvc.pt

Jorge Ribeiro

- jribeiro@estg.ipvc.pt

Índice

1. Introdução
2. Objetivos
3. Ferramentas Utilizadas
4. Dataset
5. Análise estatística do Dataset
6. Código
7. Execução das Scripts com adaptação do código
8. Conclusão
9. Referências

Introdução

Este trabalho tem como objetivo **explorar um dataset obtido a partir de várias plataformas de uma instituição pública orientada à prestação de serviços ao cidadão.** A análise foca-se na **caracterização estatística dos dados e na identificação de padrões relevantes,** recorrendo a **técnicas de estatística descritiva e inferencial, visualização de dados e métodos de clustering.** Para garantir uma visão abrangente, a exploração é suportada por diferentes ferramentas e abordagens, culminando na criação de dashboards que consolidam os principais resultados numa única página.

Objetivos

Assim, os objetivos deste trabalho são os seguintes:

- **Integrar o dataset** nas ferramentas indicadas e realizar uma exploração completa (EDA).
- **Calcular e apresentar estatísticas de 1.º e 2.º nível** (n, min, max, média, mediana, moda, quartis, desvio padrão).
- **Analisar distribuições e pressupostos** (normalidade, binomial, Poisson e t-Student), apoiados por visualizações e testes.
- **Explorar relações entre variáveis** (heatmap de correlações e scatterplot matrix).
- **Aplicar clustering** (K-Means) **com validação** (silhouette/elbow/Calinski-Harabasz) e **visualização** (PCA), e consolidar resultados em dashboards numa página.

Ferramentas Utilizadas

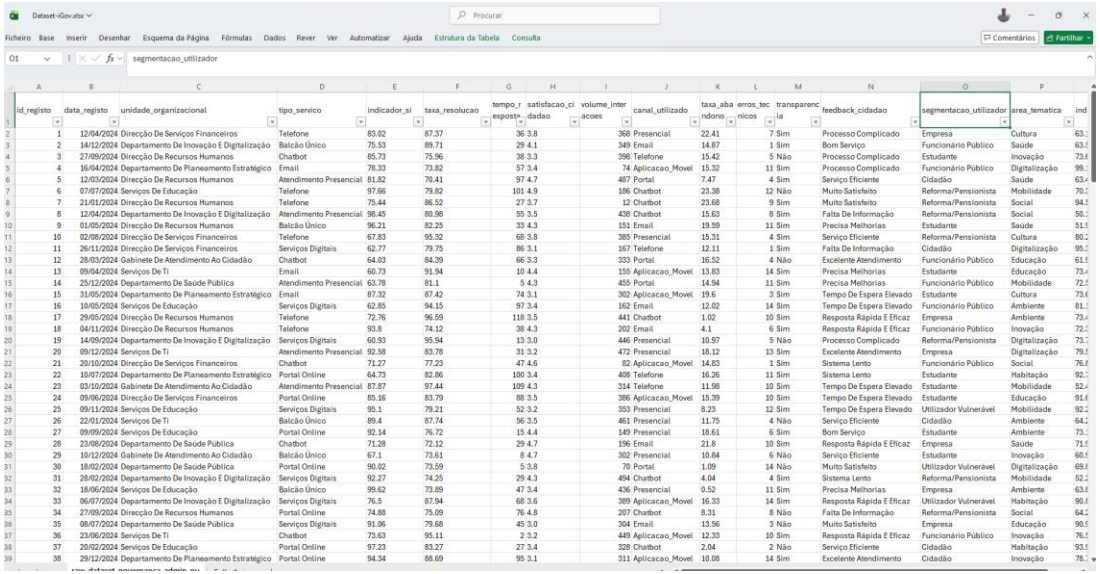


Python: Linguagem de programação versátil para desenvolvimento, automação e IA. Foi também utilizada para escrever os scripts deste trabalho.

kaggle™

Kaggle: Plataforma focada em Data Science utilizada para executar os scripts em Python.

Dataset



id_registo	data_registo	unidade_organizacional	tipo_serviço	indicador_si	taxa_resolucao	tempo_r espost*	satisfacao_ci dadao	volume_inter acoes	canal_utilizado	taxa_aba ndono	erros_tec nicos	transparenc ia	feedback_cidadao	segmentacao_utilizador	area_tematica	ind
1	12/04/2024	Direcção De Serviços Financeiros	Telefone	83.02	87.37	36	3.8	368	Presencial	22.41	7	Sim	Processo Complicado	Empresa	Cultura	63.
2	14/12/2024	Departamento De Inovação E Digitalização	Balcão Único	75.53	89.71	29	4.1	349	Email	14.87	1	Sim	Bom Serviço	Funcionário Público	Saúde	63.
3	27/09/2024	Direcção De Recursos Humanos	Chatbot	85.73	75.96	38	3.3	398	Telefone	15.42	5	Não	Processo Complicado	Estudante	Inovação	73.
4	16/04/2024	Departamento De Planeamento Estratégico	Email	78.33	73.82	57	3.4	74	Aplicacao_Movel	15.32	11	Sim	Processo Complicado	Funcionário Público	Digitalização	99.
5	12/03/2024	Direcção De Recursos Humanos	Atendimento Presencial	81.82	78.41	97	4.7	487	Portal	7.47	4	Sim	Serviço Eficiente	Cidadão	Saúde	63.
6	07/07/2024	Serviços De Educação	Telefone	97.66	79.82	101	4.9	186	Chatbot	23.38	12	Não	Muito Satisfeito	Reforma/Pensionista	Mobilidade	70.
7	21/01/2024	Direcção De Recursos Humanos	Telefone	75.44	86.52	27	3.7	12	Chatbot	23.68	9	Sim	Muito Satisfeito	Reforma/Pensionista	Social	94.
8	12/04/2024	Departamento De Inovação E Digitalização	Atendimento Presencial	98.45	80.98	55	3.5	438	Chatbot	15.63	8	Sim	Falta De Informação	Reforma/Pensionista	Social	50.
9	01/05/2024	Direcção De Recursos Humanos	Balcão Único	96.21	82.25	33	4.3	151	Email	19.59	11	Sim	Precisa Melhorias	Estudante	Saúde	51.
10	02/08/2024	Direcção De Serviços Financeiros	Telefone	67.83	95.32	68	3.8	385	Presencial	15.31	4	Sim	Serviço Eficiente	Reforma/Pensionista	Cultura	80.
11	26/11/2024	Direcção De Serviços Financeiros	Serviços Digitais	62.77	79.75	86	3.1	167	Telefone	12.11	1	Sim	Falta De Informação	Cidadão	Digitalização	95.
12	28/03/2024	Gabinete De Atendimento Ao Cidadão	Chatbot	64.03	84.39	66	3.3	333	Portal	16.52	4	Não	Excelente Atendimento	Funcionário Público	Educação	61.
13	09/04/2024	Serviços De TI	Email	60.73	91.94	10	4.4	155	Aplicacao_Movel	13.83	14	Sim	Precisa Melhorias	Estudante	Educação	73.
14	25/12/2024	Departamento De Saúde Pública	Atendimento Presencial	63.78	81.1	5	4.3	455	Portal	14.94	11	Sim	Precisa Melhorias	Funcionário Público	Mobilidade	72.
15	31/05/2024	Departamento De Planeamento Estratégico	Email	87.32	87.42	74	3.1	302	Aplicacao_Movel	19.6	3	Sim	Tempo De Espera Elevado	Estudante	Cultura	73.
16	10/05/2024	Serviços De Educação	Serviços Digitais	62.85	94.15	97	3.4	162	Email	12.02	14	Sim	Tempo De Espera Elevado	Funcionário Público	Ambiente	81.
17	29/05/2024	Direcção De Recursos Humanos	Telefone	72.76	96.59	118	3.5	441	Chatbot	1.02	10	Sim	Resposta Rápida E Eficaz	Empresa	Ambiente	73.
18	04/11/2024	Direcção De Recursos Humanos	Telefone	93.8	74.12	38	4.3	202	Email	4.1	6	Sim	Resposta Rápida E Eficaz	Funcionário Público	Inovação	72.
19	14/09/2024	Departamento De Inovação E Digitalização	Serviços Digitais	60.93	95.94	13	3.0	446	Presencial	10.97	5	Não	Processo Complicado	Reforma/Pensionista	Digitalização	73.
20	09/12/2024	Serviços De TI	Atendimento Presencial	92.58	83.78	31	3.2	472	Presencial	18.12	13	Sim	Excelente Atendimento	Empresa	Digitalização	79.
21	20/10/2024	Direcção De Serviços Financeiros	Chatbot	71.27	77.23	47	4.6	82	Aplicacao_Movel	14.83	1	Sim	Sistema Lento	Funcionário Público	Social	76.
22	10/07/2024	Departamento De Planeamento Estratégico	Portal Online	64.73	82.86	100	3.4	408	Telefone	16.26	11	Sim	Sistema Lento	Estudante	Habitação	92.
23	03/10/2024	Gabinete De Atendimento Ao Cidadão	Atendimento Presencial	87.87	97.44	109	4.3	314	Telefone	11.98	10	Sim	Tempo De Espera Elevado	Estudante	Mobilidade	52.
24	09/06/2024	Direcção De Serviços Financeiros	Portal Online	85.16	83.79	88	3.5	386	Aplicacao_Movel	15.39	10	Sim	Tempo De Espera Elevado	Estudante	Educação	91.
25	09/11/2024	Serviços De Educação	Serviços Digitais	95.1	79.21	52	3.2	353	Presencial	8.23	12	Sim	Tempo De Espera Elevado	Utilizador Vulnerável	Mobilidade	92.
26	22/01/2024	Serviços De TI	Balcão Único	89.4	87.74	56	3.5	461	Presencial	11.75	4	Não	Serviço Eficiente	Cidadão	Ambiente	64.
27	09/09/2024	Serviços De Educação	Portal Online	92.14	76.72	15	4.4	149	Presencial	18.61	6	Sim	Bom Serviço	Estudante	Ambiente	73.
28	23/08/2024	Departamento De Saúde Pública	Chatbot	71.28	72.12	29	4.7	196	Email	21.8	10	Sim	Resposta Rápida E Eficaz	Empresa	Saúde	71.
29	10/12/2024	Gabinete De Atendimento Ao Cidadão	Balcão Único	67.1	73.61	8	4.7	302	Presencial	10.84	6	Não	Serviço Eficiente	Estudante	Inovação	60.
30	18/02/2024	Departamento De Saúde Pública	Portal Online	90.02	73.59	5	3.8	70	Portal	1.09	14	Não	Muito Satisfeito	Utilizador Vulnerável	Digitalização	69.
31	28/02/2024	Departamento De Inovação E Digitalização	Serviços Digitais	92.27	74.25	29	4.3	494	Chatbot	4.04	4	Sim	Sistema Lento	Reforma/Pensionista	Mobilidade	52.
32	18/06/2024	Serviços De Educação	Balcão Único	99.62	73.89	47	3.4	436	Presencial	0.52	11	Sim	Precisa Melhorias	Empresa	Ambiente	63.
33	06/07/2024	Departamento De Inovação E Digitalização	Serviços Digitais	76.5	87.94	68	3.6	389	Aplicacao_Movel	16.33	14	Sim	Resposta Rápida E Eficaz	Utilizador Vulnerável	Habitação	90.
34	27/09/2024	Direcção De Recursos Humanos	Portal Online	74.88	75.09	76	4.8	207	Chatbot	8.31	8	Não	Falta De Informação	Reforma/Pensionista	Social	64.
35	08/07/2024	Departamento De Saúde Pública	Serviços Digitais	91.06	79.68	45	3.0	304	Email	13.56	3	Não	Muito Satisfeito	Empresa	Educação	90.
36	23/06/2024	Serviços De TI	Chatbot	73.63	95.11	2	3.2	449	Aplicacao_Movel	12.33	10	Sim	Resposta Rápida E Eficaz	Funcionário Público	Inovação	76.
37	20/02/2024	Serviços De Educação	Portal Online	97.23	83.27	27	3.4	328	Chatbot	2.04	2	Não	Serviço Eficiente	Cidadão	Habitação	93.
38	29/12/2024	Departamento De Planeamento Estratégico	Portal Online	94.34	88.69	95	3.1	311	Aplicacao_Movel	10.08	14	Sim	Excelente Atendimento	Cidadão	Inovação	78.

O dataset analisado é composto por **200 registos e 17 variáveis**, contendo **informação quantitativa e categórica** relativa ao desempenho e utilização de serviços. As variáveis incluem **indicadores de desempenho** (taxa de resolução, tempo de resposta, indicador KPI), **métricas operacionais** (volume de interações, erros técnicos, taxa de abandono) e **atributos de caracterização** (tipo de serviço, canal utilizado, área temática e data de registo).

Fonte: Ficheiro disponibilizado pelo docente na plataforma Moodle

Análise estatística do Dataset

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 17 columns):
 #   Column                  Non-Null Count  Dtype
---  ------                  --------------  -----
 0   id_registo              200 non-null    int64
 1   data_registo            200 non-null    object
 2   unidade_organizacional  200 non-null    object
 3   tipo_servico            200 non-null    object
 4   indicador_si            200 non-null    float64
 5   taxa_resolucao          200 non-null    float64
 6   tempo_resposta          200 non-null    int64
 7   satisfacao_cidadao      200 non-null    float64
 8   volume_interacoes       200 non-null    int64
 9   canal_utilizado         200 non-null    object
 10  taxa_abandono           200 non-null    float64
 11  erros_tecnicos          200 non-null    int64
 12  transparencia           200 non-null    object
 13  feedback_cidadao        200 non-null    object
 14  segmentacao_utilizador  200 non-null    object
 15  area_tematica           200 non-null    object
 16  indicador_kpi           200 non-null    float64
dtypes: float64(5), int64(4), object(8)
memory usage: 26.7+ KB
```

Através do ***df.head(), df.shape, df.columns.tolist(), df.info()***, podemos observar o número de registos/colunas e tipos.

Análise estatística do Dataset

	count	unique	top	freq	mean	std	min	25%	50%	75%	max
id_registo	200.0	NaN	NaN	NaN	100.5	57.879185	1.0	50.75	100.5	150.25	200.0
data_registo	200	152	2024-08-18	4	NaN	NaN	NaN	NaN	NaN	NaN	NaN
unidade_organizacional	200	8	Serviços De Educação	38	NaN	NaN	NaN	NaN	NaN	NaN	NaN
tipo_servico	200	7	Portal Online	36	NaN	NaN	NaN	NaN	NaN	NaN	NaN
indicador_si	200.0	NaN	NaN	NaN	81.58325	12.373367	60.43	71.3925	82.39	92.5575	99.99
taxa_resolucao	200.0	NaN	NaN	NaN	82.90985	7.76995	70.41	75.84	82.275	88.7925	97.72
tempo_resposta	200.0	NaN	NaN	NaN	58.73	33.991088	1.0	29.75	54.5	88.25	118.0
satisfacao_cidadao	200.0	NaN	NaN	NaN	3.9855	0.591089	3.0	3.5	4.0	4.5	5.0
volume_interacoes	200.0	NaN	NaN	NaN	251.59	142.126781	12.0	131.25	251.0	366.5	499.0
canal_utilizado	200	6	Presencial	38	NaN	NaN	NaN	NaN	NaN	NaN	NaN
taxa_abandono	200.0	NaN	NaN	NaN	12.5555	6.56837	0.23	7.8975	13.325	16.595	24.83
erros_tecnicos	200.0	NaN	NaN	NaN	7.035	4.17624	0.0	3.0	7.0	11.0	14.0
transparencia	200	2	Sim	149	NaN	NaN	NaN	NaN	NaN	NaN	NaN
feedback_cidadao	200	10	Sistema Lento	24	NaN	NaN	NaN	NaN	NaN	NaN	NaN
segmentacao_utilizador	200	6	Empresa	37	NaN	NaN	NaN	NaN	NaN	NaN	NaN
area_tematica	200	9	Social	30	NaN	NaN	NaN	NaN	NaN	NaN	NaN
indicador_kpi	200.0	NaN	NaN	NaN	75.1668	14.210823	50.11	63.075	75.475	87.61	99.99

Para as **variáveis numéricas**, são calculadas métricas como a **média (mean)**, que representa o valor médio esperado; o **desvio padrão (std)**, que mede a dispersão dos valores em torno da média; o **mínimo (min)** e **máximo (max)**, que indicam os extremos observados; e os **quartis (25%, 50%, 75%)**, que dividem os dados em quatro partes iguais, sendo 50% equivalente à mediana.

Análise estatística do Dataset

	count	unique	top	freq	mean	std	min	25%	50%	75%	max
id_registo	200.0	NaN	NaN	NaN	100.5	57.879185	1.0	50.75	100.5	150.25	200.0
data_registo	200	152	2024-08-18	4	NaN	NaN	NaN	NaN	NaN	NaN	NaN
unidade_organizacional	200	8	Serviços De Educação	38	NaN	NaN	NaN	NaN	NaN	NaN	NaN
tipo_servico	200	7	Portal Online	36	NaN	NaN	NaN	NaN	NaN	NaN	NaN
indicador_si	200.0	NaN	NaN	NaN	81.58325	12.373367	60.43	71.3925	82.39	92.5575	99.99
taxa_resolucao	200.0	NaN	NaN	NaN	82.90985	7.76995	70.41	75.84	82.275	88.7925	97.72
tempo_resposta	200.0	NaN	NaN	NaN	58.73	33.991088	1.0	29.75	54.5	88.25	118.0
satisfacao_cidadao	200.0	NaN	NaN	NaN	3.9855	0.591089	3.0	3.5	4.0	4.5	5.0
volume_interacoes	200.0	NaN	NaN	NaN	251.59	142.126781	12.0	131.25	251.0	366.5	499.0
canal_utilizado	200	6	Presencial	38	NaN	NaN	NaN	NaN	NaN	NaN	NaN
taxa_abandono	200.0	NaN	NaN	NaN	12.5555	6.56837	0.23	7.8975	13.325	16.595	24.83
erros_tecnicos	200.0	NaN	NaN	NaN	7.035	4.17624	0.0	3.0	7.0	11.0	14.0
transparencia	200	2	Sim	149	NaN	NaN	NaN	NaN	NaN	NaN	NaN
feedback_cidadao	200	10	Sistema Lento	24	NaN	NaN	NaN	NaN	NaN	NaN	NaN
segmentacao_utilizador	200	6	Empresa	37	NaN	NaN	NaN	NaN	NaN	NaN	NaN
area_tematica	200	9	Social	30	NaN	NaN	NaN	NaN	NaN	NaN	NaN
indicador_kpi	200.0	NaN	NaN	NaN	75.1668	14.210823	50.11	63.075	75.475	87.61	99.99

Nas **variáveis categóricas**, surgem métricas como **count** (número de valores não nulos), **unique** (número de categorias distintas), **top** (categoria mais frequente) e **freq** (frequência dessa categoria).

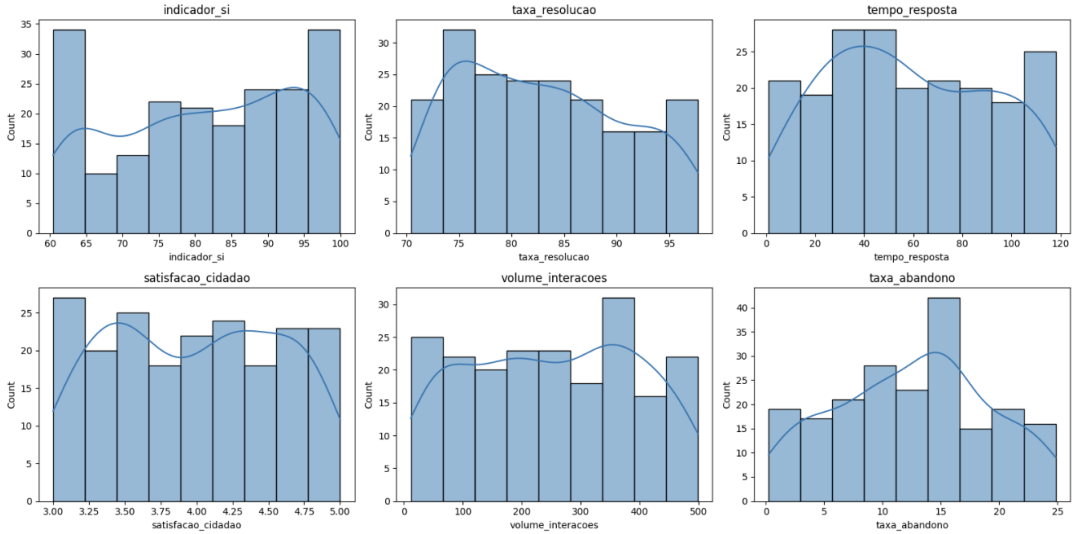
O valor **NaN (Not a Number)** aparece quando determinada métrica não é aplicável a um tipo de variável. Por exemplo, não faz sentido calcular média ou desvio padrão para variáveis categóricas, pelo que essas células aparecem como NaN.

Análise estatística do Dataset

variavel	n	min	q1	mediana	media	q3	max	moda	desvio_padrao
indicador_si	200	60.43	71.3925	82.390	81.58325	92.5575	99.99	63.65	12.373367
taxa_resolucao	200	70.41	75.8400	82.275	82.90985	88.7925	97.72	76.79	7.769950
tempo_resposta	200	1.00	29.7500	54.500	58.73000	88.2500	118.00	29.00	33.991088
satisfacao_cidadao	200	3.00	3.5000	4.000	3.98550	4.5000	5.00	3.50	0.591089
volume_interacoes	200	12.00	131.2500	251.000	251.59000	366.5000	499.00	49.00	142.126781
taxa_abandono	200	0.23	7.8975	13.325	12.55550	16.5950	24.83	8.98	6.568370
erros_tecnicos	200	0.00	3.0000	7.000	7.03500	11.0000	14.00	9.00	4.176240
indicador_kpi	200	50.11	63.0750	75.475	75.16680	87.6100	99.99	52.24	14.210823

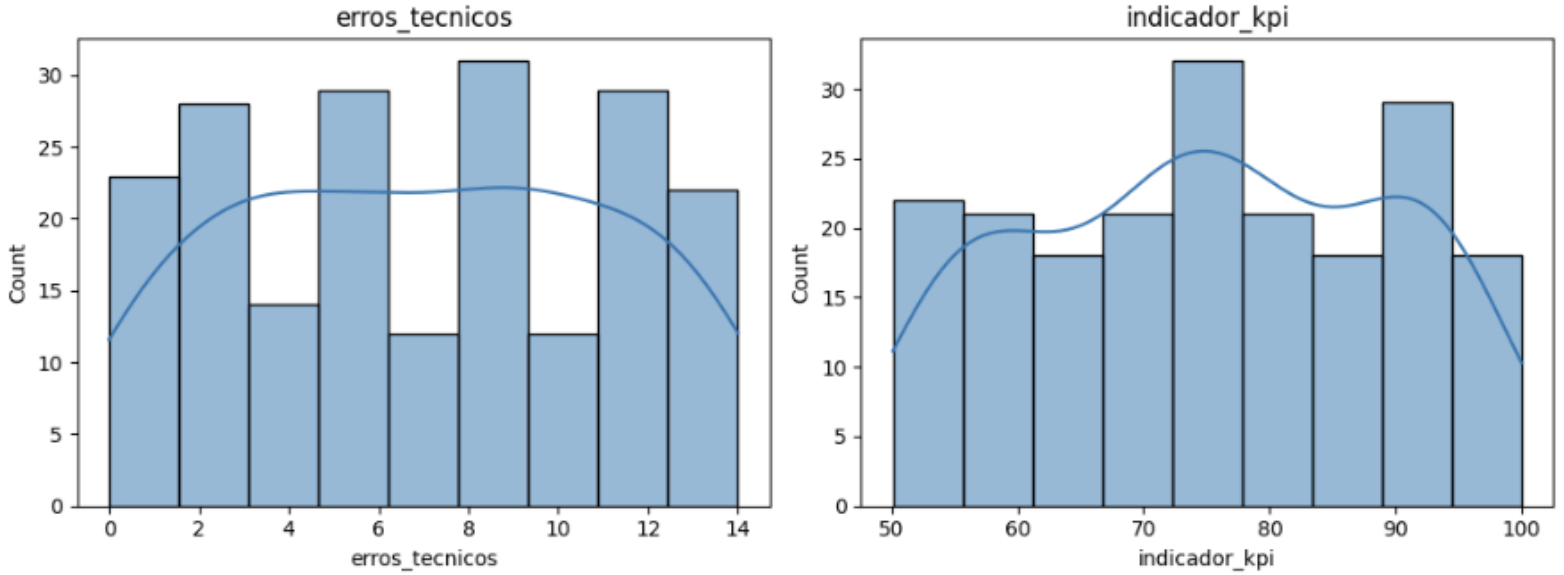
Esta tabela resume as **estatísticas descritivas** das variáveis numéricas. O **n** é o número de registos analisados; **min** e **max** são os limites observados; **q1**, **mediana** e **q3** mostram a posição dos dados por quartis (25%, 50% e 75%); a **média** indica o valor típico; a **moda** é o valor mais frequente; e o **desvio padrão** mede a dispersão (quanto maior, mais variabilidade). Aqui nota-se maior variabilidade no **tempo_resposta** e **volume_interacoes**, havendo valores mais estáveis na **satisfacao_cidadao**.

Análise estatística do Dataset



Os histogramas mostram a distribuição e a dispersão das variáveis numéricas, ajudando a identificar concentrações, assimetrias e possíveis outliers. O **indicador_si** e **taxa_resolucao** apresentam maior concentração em valores médios-altos, sugerindo desempenho global relativamente consistente. **tempo_resposta** e **volume_interacoes** têm maior variabilidade, indicando diferenças relevantes entre registos. **satisfacao_cidadao** concentra-se sobretudo entre 3 e 5, sugerindo tendência para avaliações positivas, enquanto **taxa_abandono** surge mais espalhada, o que pode refletir comportamentos distintos de utilização/serviço.

Análise estatística do Dataset



Estes histogramas focam variáveis com impacto operacional. **erros_tecnicos** é uma variável de contagem, adequada para análise por Poisson, e mostra distribuição dispersa ao longo do intervalo observado. **indicador_kpi** concentra-se em valores médios-altos, sugerindo um nível de desempenho geral estável.

Análise estatística do Dataset

	indicador_si				taxa_resolucao				tempo_resposta		...	taxa_abandono				erros_tecnicos				indicador_kpi			
	count	mean	median	std	count	mean	median	std	count	mean	...	median	std	count	mean	median	std	count	mean	median	std
canal_utilizado																							
Aplicacao_Movel	37	80.689	82.940	11.890	37	84.522	86.010	7.539	37	53.189	...	11.240	7.086	37	6.568	6.0	4.266	37	76.323	76.620	13.655
Chatbot	35	84.436	87.390	11.979	35	82.840	81.530	7.125	35	64.371	...	13.950	7.459	35	7.714	9.0	3.989	35	73.711	73.700	16.816
Email	32	83.581	82.885	11.105	32	81.731	79.530	8.217	32	57.594	...	13.900	5.808	32	6.531	6.0	4.421	32	73.988	72.800	14.108
Portal	30	78.529	77.455	12.289	30	83.065	83.645	8.104	30	64.633	...	14.765	5.711	30	7.300	7.0	4.203	30	73.772	72.480	14.130
Presencial	38	81.443	84.080	13.777	38	82.891	82.845	7.969	38	54.526	...	11.310	6.167	38	7.579	7.5	3.753	38	77.543	78.045	11.598
Telefone	28	80.380	81.450	12.924	28	82.075	80.845	8.012	28	59.679	...	12.735	7.116	28	6.357	5.0	4.621	28	75.076	75.070	15.495

Esta tabela compara as estatísticas por **canal_utilizado** (count, média, mediana e desvio padrão) para várias métricas. Permite identificar diferenças de desempenho e comportamento entre canais, por exemplo variações na **taxa_resolucao**, **tempo_resposta** e **indicador_kpi**, ajudando a perceber que o canal pode influenciar os resultados e a variabilidade.

Análise estatística do Dataset

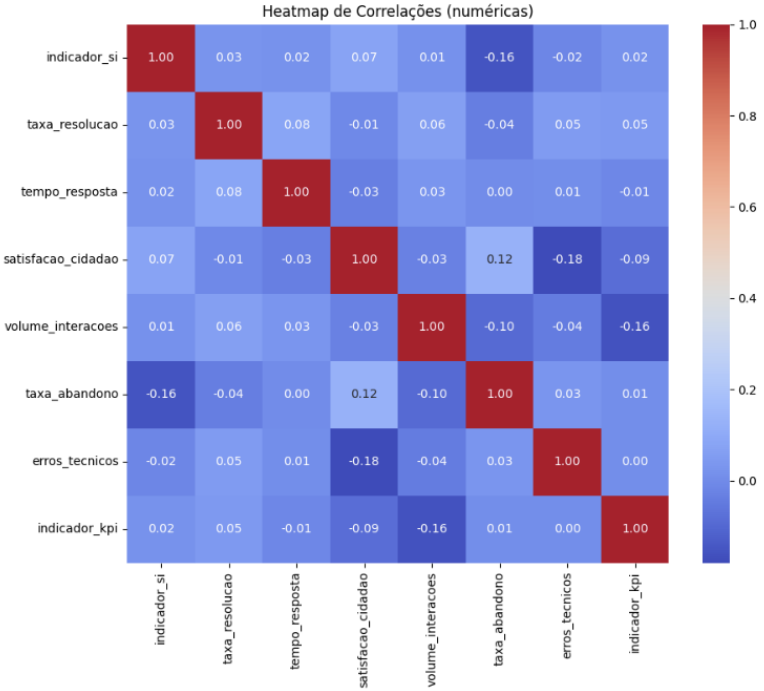
	skew	kurtosis
indicador_si	-0.195	-1.252
taxa_resolucao	0.266	-1.112
tempo_resposta	0.131	-1.130
satisfacao_cidadao	-0.000	-1.267
volume_interacoes	-0.023	-1.215
taxa_abandono	-0.054	-0.873
erros_tecnicos	0.002	-1.141
indicador_kpi	-0.051	-1.131

Esta tabela apresenta a **assimetria (skewness)** e a **curtose (kurtosis)** das variáveis numéricas, sendo que é quase um resumo dos histogramas.

A **skewness** mede a simetria da distribuição: valores próximos de 0 indicam distribuição aproximadamente simétrica. Aqui, todos os valores estão perto de zero, o que sugere baixa assimetria.

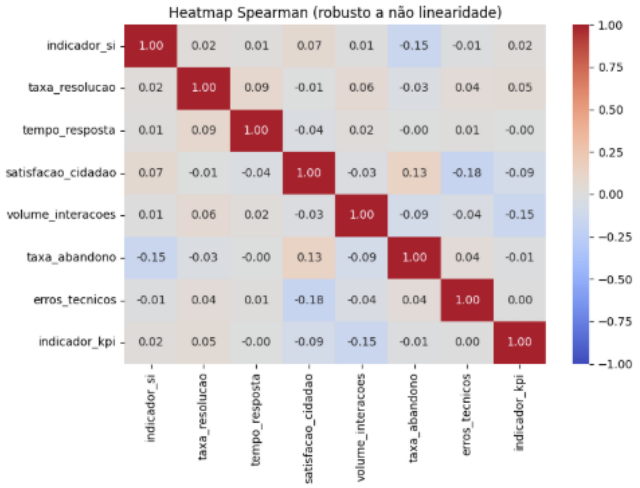
A **kurtosis** mede o grau de concentração nas caudas. Valores negativos indicam distribuições mais “achatadas” do que a Normal (platicúrticas). Neste caso, todas as variáveis apresentam curtose negativa, sugerindo distribuições relativamente dispersas e sem caudas extremas acentuadas.

Análise estatística do Dataset



O **heatmap** mostra a correlação linear entre variáveis numéricas (de -1 a 1). Aqui, a maioria dos valores está perto de 0, o que indica relações fracas e pouca redundância entre variáveis. As correlações negativas mais visíveis são (**satisfacao_cidadao** e **erros_técnicos, volume_interacoes** e **indicador_kpi**).

Análise estatística do Dataset



Este heatmap apresenta as **correlações de Spearman (ρ)** entre variáveis numéricas. Esta métrica avalia **associações monotónicas** e é **mais robusta a outliers** do que a correlação de Pearson. Observa-se que a maioria dos coeficientes está **próxima de zero**, indicando **relações fracas** entre as variáveis. Existem apenas tendências ligeiras, por exemplo, entre **satisfacao_cidadao**, **erros_tecnicos** e **taxa_abandono**, o que sugere baixa dependência direta e favorece a análise multivariada/clustering.

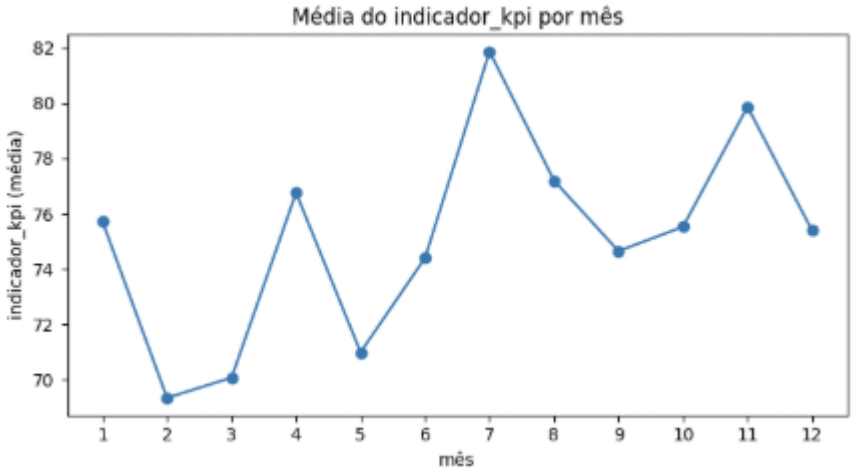
Análise estatística do Dataset

	var1	var2	spearman	abs
20	satisfacao_cidadao	erros_tecnicos	-0.176215	0.176215
4	indicador_si	taxa_abandono	-0.153563	0.153563
24	volume_interacoes	indicador_kpi	-0.153400	0.153400
19	satisfacao_cidadao	taxa_abandono	0.134422	0.134422
21	satisfacao_cidadao	indicador_kpi	-0.092655	0.092655
7	taxa_resolucao	tempo_resposta	0.091505	0.091505
22	volume_interacoes	taxa_abandono	-0.090534	0.090534
2	indicador_si	satisfacao_cidadao	0.073528	0.073528
9	taxa_resolucao	volume_interacoes	0.062848	0.062848
12	taxa_resolucao	indicador_kpi	0.051549	0.051549

Esta tabela resume as **correlações de Spearman** entre pares de variáveis, destacando os valores com maior |ρ| (maior magnitude). No geral, os coeficientes são **baixos**, confirmando que **não existem relações monotónicas fortes** entre as variáveis.

Assim, os padrões observados tendem a resultar da **combinação de vários atributos**, em vez de uma dependência forte entre apenas duas variáveis.

Análise estatística do Dataset



Este gráfico mostra a evolução mensal da média do **indicador_kpi**, permitindo identificar variações ao longo do ano. Observam-se oscilações moderadas, com picos e quebras pontuais, o que indica que o desempenho não é totalmente estável ao longo dos meses.

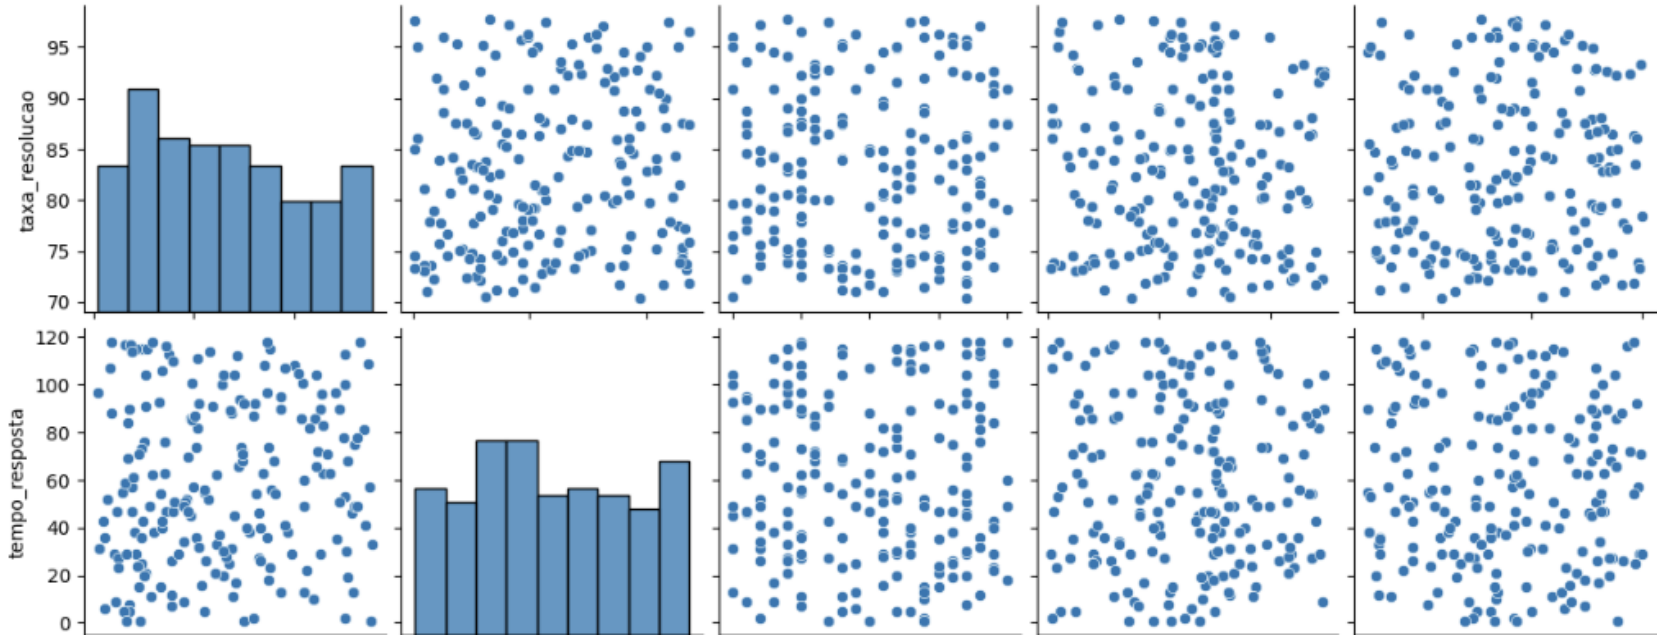
Análise estatística do Dataset

	H	p_value
indicador_kpi	2.225043	0.817211
tempo_resposta	2.934611	0.710066
satisfacao_cidadao	11.224759	0.047101
taxa_resolucao	3.018306	0.697163

mes	indicador_kpi	tempo_resposta	satisfacao_cidadao	taxa_resolucao
1	75.71	44.85	3.88	82.19
2	69.34	60.14	4.03	80.17
3	70.07	63.42	4.02	88.07
4	76.76	62.71	4.14	87.26
5	70.99	51.00	3.96	84.24
6	74.40	43.75	4.05	82.61
7	81.87	65.62	3.97	83.77
8	77.20	74.08	3.98	81.86
9	74.65	61.67	3.90	80.64
10	75.53	74.43	3.93	84.14
11	79.87	56.12	3.96	82.24
12	75.40	41.74	4.00	81.56

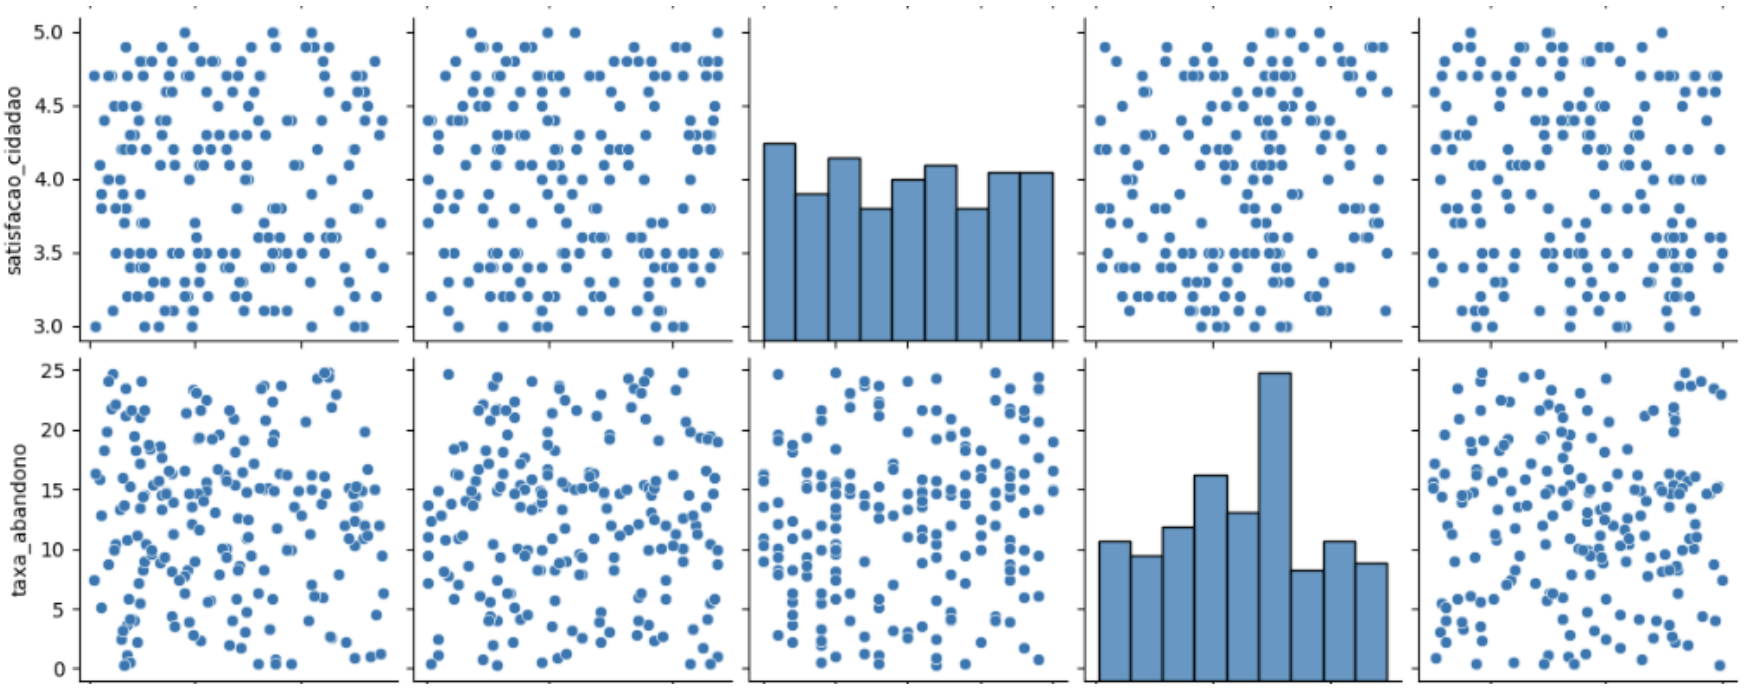
Foi realizado um teste de **comparação entre meses** (estatística H e p-value) para avaliar se as diferenças observadas são estatisticamente significativas. Verifica-se evidência de variação mensal significativa no **indicador_kpi** e na **satisfacao_cidadao** ($p < 0.05$), enquanto **tempo_resposta** e **taxa_resolucao** não apresentam diferenças mensais estatisticamente relevantes.

Análise estatística do Dataset



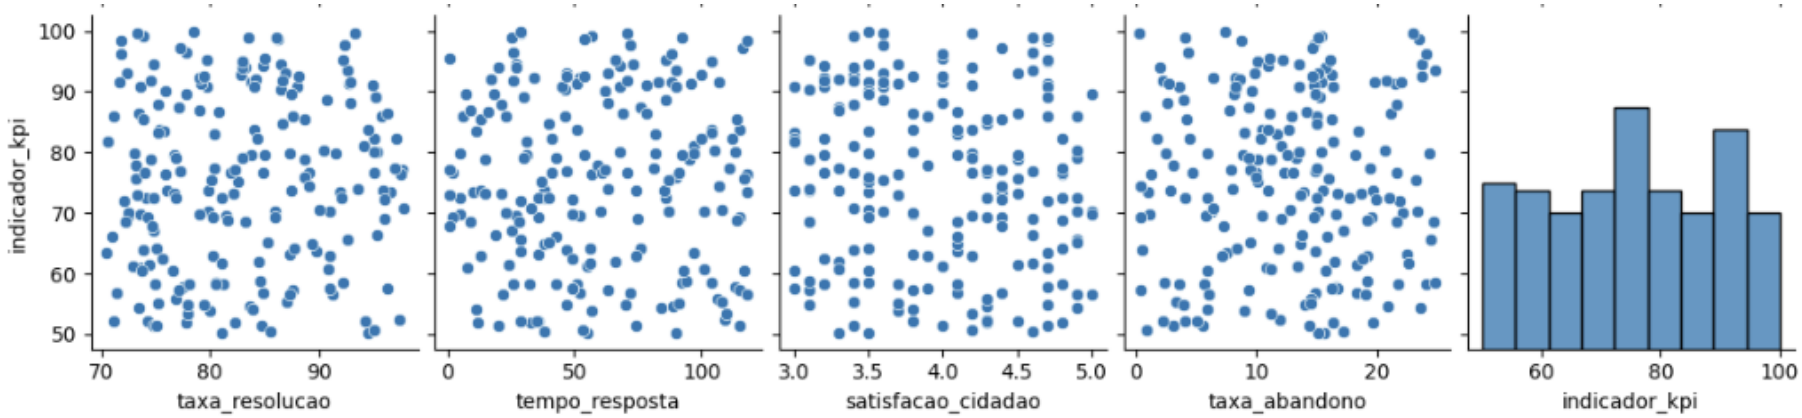
Os **scatterplots** permitem analisar relações bivariadas entre variáveis. Nesta primeira matriz, não se observam padrões lineares fortes entre **taxa_resolucao** e **tempo_resposta**, o que sugere fraca dependência direta entre desempenho e tempo. A dispersão relativamente homogénea confirma a baixa correlação identificada anteriormente.

Análise estatística do Dataset



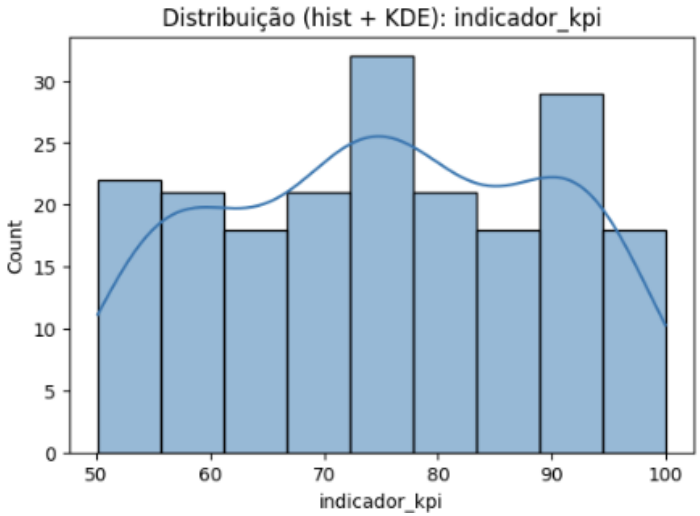
Nesta secção observa-se a relação entre níveis de satisfação e abandono. A distribuição dos pontos é bastante dispersa, indicando ausência de relação linear forte. Ainda assim, é possível notar ligeiras tendências que podem justificar análise complementar, sobretudo na ligação entre satisfação e abandono.

Análise estatística do Dataset



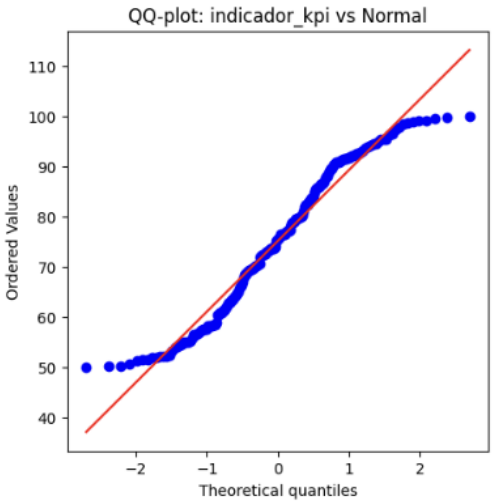
Os gráficos que envolvem o **indicador_kpi** mostram dispersão elevada face às restantes variáveis, sem padrões lineares claros. Isto sugere que o KPI não depende isoladamente de uma única variável, mas sim de múltiplos fatores combinados, reforçando a necessidade de técnicas multivariadas como o clustering.

Análise estatística do Dataset



Na parte da **Normalidade**, o histograma com KDE permite visualizar a forma da distribuição do **indicador_kpi**, mostrando concentração maior em valores médios-altos e alguma assimetria nas extremidades. O QQ-plot compara os quantis observados com uma distribuição Normal teórica; o afastamento da linha de referência nas caudas indica desvio à normalidade.

Análise estatística do Dataset



ShapiroResult(statistic=np.float64(0.9529401634534156), pvalue=np.float64(5.7934628694992704e-05))

O teste de **Shapiro-Wilk** apresenta p-value ≈ 5.79×10^{-5} (< 0.05), o que leva à rejeição da hipótese de normalidade. Assim, a variável não segue uma distribuição Normal perfeita, sendo recomendável considerar abordagens robustas ou não paramétricas quando necessário.

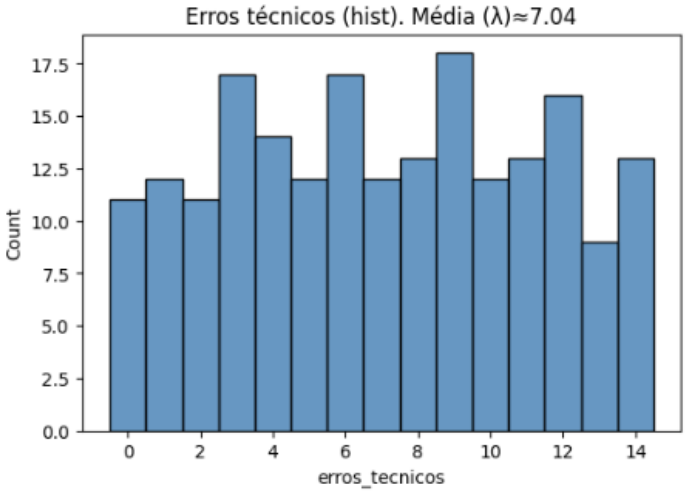
Análise estatística do Dataset

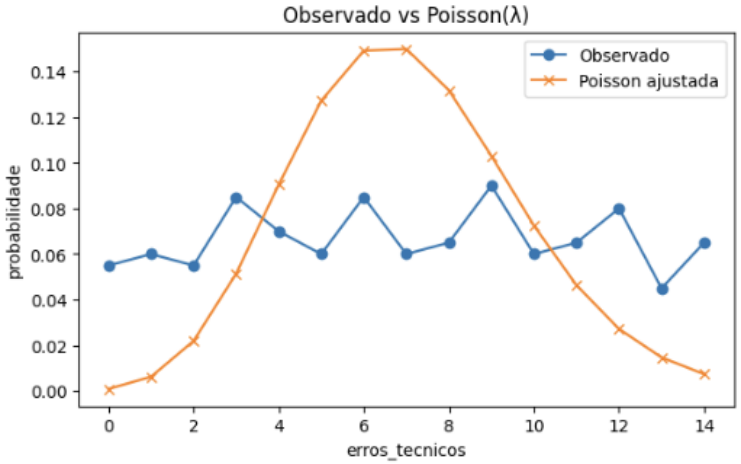
	indicador_kpi	taxa_resolucao	tempo_resposta	satisfacao_cidadao
W	0.952940	0.938509	0.944084	0.934774
p_value	0.000058	0.000004	0.000011	0.000002

Esta tabela mostra os resultados do teste de **Shapiro-Wilk** para normalidade. O valor **W** indica quão próxima a distribuição está da Normal, e o **p_value** decide o teste: quando **p_value < 0.05**, rejeita-se a hipótese de normalidade.

Aqui, todos os p-values são muito baixos, logo **as variáveis testadas não seguem uma distribuição Normal** de forma estatisticamente significativa. Isto justifica complementar a análise com visualizações (histogramas/QQ-plot) e, quando necessário, usar métodos mais robustos ou não paramétricos.

Análise estatística do Dataset





Quanto a **Poisson**, o histograma apresenta a distribuição da variável **erros_tecnicos**, que é uma variável de contagem. A média estimada é $\lambda \approx 7.04$, valor utilizado como parâmetro da distribuição de Poisson.

No gráfico comparativo, observa-se a probabilidade empírica face à curva da **Poisson ajustada**. Embora exista alguma aproximação em torno da média, verificam-se diferenças nas extremidades, indicando que a distribuição real não é perfeitamente Poisson, mas a modelação é adequada como aproximação para eventos de contagem.

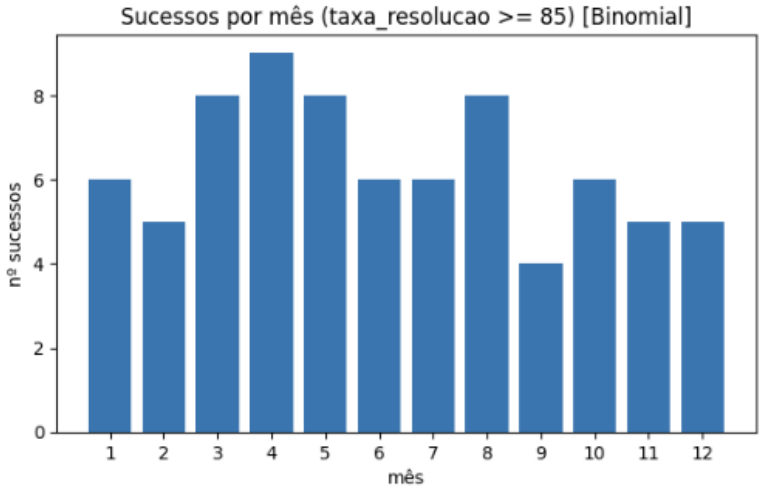
Análise estatística do Dataset

```
(np.float64(7.035), 17.440979899497496)

Sobredispersão (var > mean): Poisson simples tende a ajustar mal.
```

Para a variável **erros_tecnicos**, obteve-se média ≈ 7.04 e variância ≈ 17.44. Como a variância é significativamente superior à média, verifica-se **sobredispersão**, o que indica que o modelo de Poisson simples (que assume que média ≈ variância) pode não ajustar perfeitamente aos dados.

Análise estatística do Dataset



No tópico **Binomial**, definiu-se sucesso como **taxa_resolucao** ≥ 85. No total, houve 76 sucessos em 200 registos ($\hat{p}$ = 76/200 ≈ 0.38).

Isto pode ser modelado por uma Binomial: $X \sim Binomial(n = 200 p \approx 0.38)$ e o gráfico mostra os sucessos por mês.

Análise estatística do Dataset

```
(np.float64(0.38), 0.3155900584867362, 0.4489328198438078)
```

```
canal_utilizado
Aplicacao_Movel    0.540541
Portal             0.433333
Presencial         0.368421
Chatbot            0.342857
Email              0.312500
Telefone           0.250000
Name: sucesso, dtype: float64
```

Foi estimada a proporção de sucesso (taxa_resolucao ≥ 85), obtendo-se $\hat{p} \approx 0.38$. O intervalo de confiança a 95% (método de Wilson) situa-se aproximadamente entre **0.316 e 0.449**, indicando a incerteza associada à estimativa.

Ao analisar por canal utilizado, verifica-se maior proporção de sucesso na **Aplicação Móvel** (~0.51) e no **Portal** (~0.43), enquanto o **Telefone** apresenta o valor mais baixo (~0.25). Isto sugere diferenças de desempenho consoante o canal de interação.

Análise estatística do Dataset

```
(np.float64(75.16680000000001),
 np.float64(73.18526573549076),
 np.float64(77.14833426450926))
```

Foi aplicado o teste **t-Student** para estimar o intervalo de confiança da média do **indicador_kpi**, assumindo o desvio padrão populacional desconhecido. A média amostral é aproximadamente 75.17 e o intervalo de confiança a 95% situa-se entre 73.19 e 77.15.

Isto significa que, com 95% de confiança, a **média real do indicador_kpi na população estará dentro deste intervalo**.

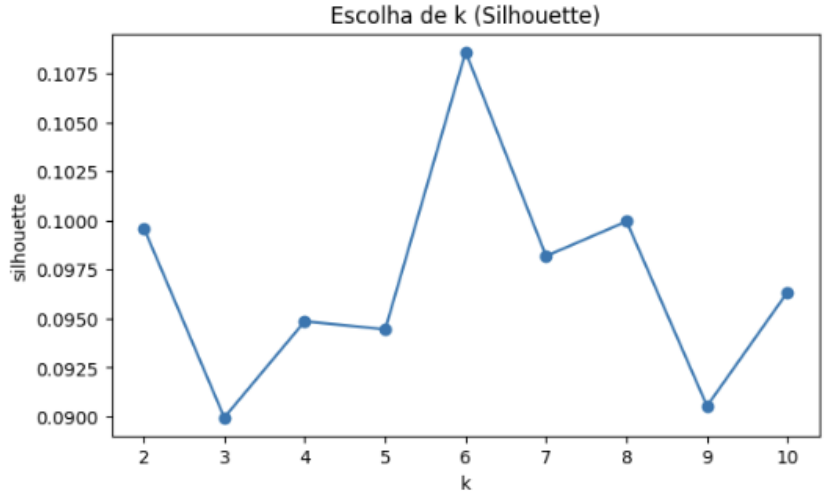
Análise estatística do Dataset

	indicador_kpi				taxa_resolucao				tempo_resposta		...	taxa_abandono		erros_tecnicos			volume_interacoes			
	count	mean	median	std	count	mean	median	std	count	mean	...	median	std	count	mean	median	std	count	mean	median	std
canal_utilizado																				
Aplicacao_Movel	37	76.323	76.620	13.655	37	84.522	86.010	7.539	37	53.189	...	11.240	7.086	37	6.568	6.0	4.266	37	248.054	236.0	134.729
Chatbot	35	73.711	73.700	16.816	35	82.840	81.530	7.125	35	64.371	...	13.950	7.459	35	7.714	9.0	3.989	35	292.057	313.0	133.198
Email	32	73.988	72.800	14.108	32	81.731	79.530	8.217	32	57.594	...	13.900	5.808	32	6.531	6.0	4.421	32	236.125	217.5	148.164
Portal	30	73.772	72.480	14.130	30	83.065	83.645	8.104	30	64.633	...	14.765	5.711	30	7.300	7.0	4.203	30	264.867	295.0	156.063
Presencial	38	77.543	78.045	11.598	38	82.891	82.845	7.969	38	54.526	...	11.310	6.167	38	7.579	7.5	3.753	38	247.368	251.5	139.800
Telefone	28	75.076	75.070	15.495	28	82.075	80.845	8.012	28	59.679	...	12.735	7.116	28	6.357	5.0	4.621	28	214.857	187.0	141.940

Esta tabela compara as métricas por **canal_utilizado** (média/mediana e variabilidade). Verifica-se que **Presencial** e **Aplicação Móvel** apresentam, em média, **KPI mais elevado**, enquanto **Telefone** é o canal com **KPI mais baixo**. A **Aplicação Móvel** destaca-se também por **taxa_resolucao** superior. Já **Chatbot** e **Portal** mostram maior **volume_interacoes**, sugerindo maior intensidade de utilização.

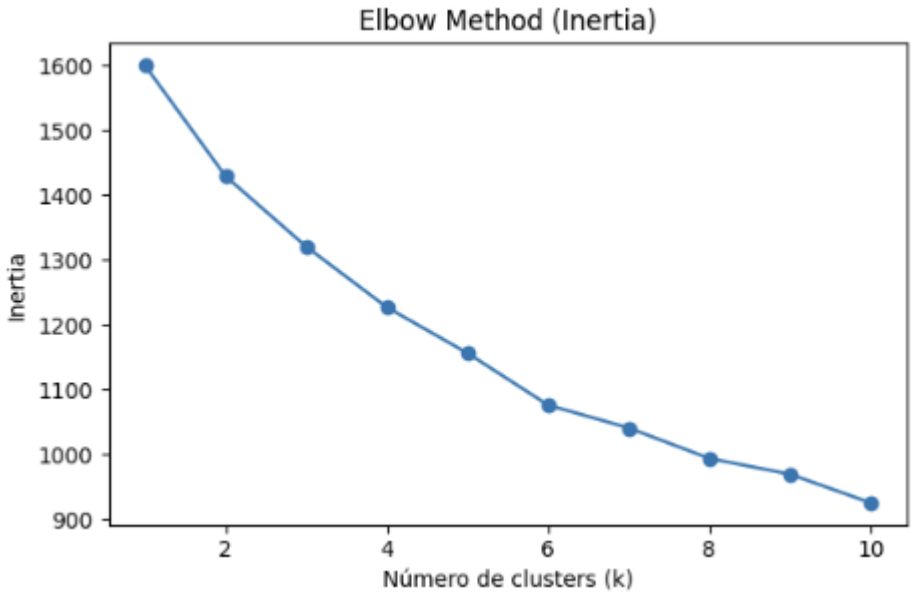
Análise estatística do Dataset

```
{2: np.float64(0.09961321704946918),
 3: np.float64(0.08995196869934531),
 4: np.float64(0.09485754370823214),
 5: np.float64(0.09444971983285352),
 6: np.float64(0.10858678852013869),
 7: np.float64(0.09818553943923196),
 8: np.float64(0.09995004778948069),
 9: np.float64(0.09053952082327328),
 10: np.float64(0.09634428417037441)}
```



No **Clustering**, foi aplicado **K-Means** às variáveis numéricas, após **normalização (StandardScaler)**, para agrupar registos com perfis semelhantes. O número de clusters foi escolhido pela métrica **Silhouette**, testando k=2…10; sendo que o melhor resultado ocorre em **k=6** (silhouette ≈ **0.109**), pelo que este valor foi selecionado.

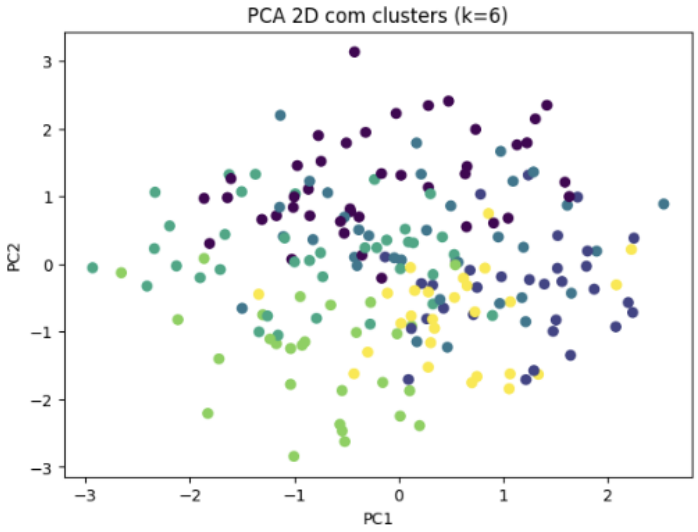
Análise estatística do Dataset




```
2     23.669686
3     20.841776
4     19.855989
5     18.699686
6     18.877729
7     17.267806
8     16.718200
9     15.515342
10    15.378764
dtype: float64
```

O **Elbow Method (inércia)** mostra uma melhoria forte nos primeiros k e uma redução mais lenta a partir de cerca de **k=5/6**, sugerindo que acima disso os ganhos são menores. O índice **Calinski-Harabasz** (quanto maior, melhor) atinge o melhor valor em **k=2** e vai diminuindo para k maiores, indicando melhor separação com menos clusters. Estas métricas funcionam como **validação adicional** e complementam o Silhouette na escolha de k.

Análise estatística do Dataset



A projeção **PCA em 2D** permite visualizar os grupos: existe alguma sobreposição entre clusters, o que indica separação moderada, mas ainda assim útil para segmentação exploratória e comparação de perfis.

Análise estatística do Dataset

```
global_mean = clustered[num_cols].mean()
```

cluster	indicador_si	taxa_resolucao	tempo_resposta	satisfacao_cidadao	volume_interacoes	taxa_abandono	erros_tecnicos	indicador_kpi
0	-2.66	-3.55	-14.33	-0.53	-25.33	0.59	2.94	8.93
1	1.37	-5.21	-14.10	0.46	-26.62	5.85	1.25	-11.38
2	-11.44	4.86	17.01	-0.18	-35.27	3.97	-1.80	-1.44
3	8.70	7.96	12.30	0.08	-52.64	-3.46	1.99	4.00
4	1.75	-3.63	23.20	-0.04	172.98	-4.91	-2.18	-11.67
5	3.18	-1.57	-23.32	0.43	8.11	-3.02	-4.26	8.05

```
cluster
0    42
1    32
2    34
3    37
4    28
5    27
Name: count, dtype: int64
```

A **distribuição de registos por cluster** mostra grupos com dimensões relativamente equilibradas, o que reduz o risco de existirem clusters residuais demasiado pequenos. A tabela de diferenças face à média global, permite interpretar cada cluster como um desvio ao comportamento médio, destacando quais métricas estão sistematicamente acima ou abaixo do esperado.

Análise estatística do Dataset

	Top1	Top2	Top3
0	volume_interacoes	tempo_resposta	indicador_kpi
1	volume_interacoes	tempo_resposta	indicador_kpi
2	volume_interacoes	tempo_resposta	indicador_si
3	volume_interacoes	tempo_resposta	indicador_si
4	volume_interacoes	tempo_resposta	indicador_kpi
5	tempo_resposta	volume_interacoes	indicador_kpi

A tabela acima identifica as variáveis que mais afastam-se da média em cada cluster, ou seja, as que mais contribuem para diferenciar os grupos. Observa-se que **volume_interacoes** e **tempo_resposta** surgem de forma recorrente como principais fatores de separação, seguidos pelo **indicador_kpi.** Isto indica que a segmentação está fortemente associada à intensidade de utilização e ao desempenho temporal do serviço, com impacto no KPI.

Análise estatística do Dataset

```
{'taxa_resolucao_out_of_range': 0,
 'satisfacao_out_of_range': 0,
 'taxa_abandono_out_of_range': 0}
```

```
id_registo                 int64
data_registo      datetime64[ns]
unidade_organizacional     object
tipo_servico               object
indicador_si              float64
taxa_resolucao            float64
tempo_resposta              int64
satisfacao_cidadao        float64
volume_interacoes           int64
canal_utilizado            object
taxa_abandono             float64
erros_tecnicos              int64
transparencia              object
feedback_cidadao           object
segmentacao_utilizador     object
area_tematica              object
indicador_kpi             float64
ano                         int32
mes                         int32
dtype: object
```

Foi verificada a consistência dos dados ao nível técnico. Foi feita uma validação de **limites plausíveis**, confirmando que não existem valores fora do intervalo esperado, do género, percentagens entre 0 e 100 e satisfação entre 0 e 5, reforçando a fiabilidade dos resultados. Além disso, **tipos de dados (dtypes)** estão coerentes com o significado das variáveis (as datas no datetime, numéricas em int/float e categorias no object), garantindo que as operações estatísticas e de clustering são aplicadas corretamente.

Análise estatística do Dataset

```
id_registo              0
data_registo            0
unidade_organizacional  0
tipo_servico            0
indicador_si            0
taxa_resolucao          0
tempo_resposta          0
satisfacao_cidadao      0
volume_interacoes       0
canal_utilizado         0
taxa_abandono           0
erros_tecnicos          0
transparencia           0
feedback_cidadao        0
segmentacao_utilizador  0
area_tematica           0
indicador_kpi           0
ano                     0
mes                     0
dtype: int64
```

```
np.int64(0)
```

Foi feita uma verificação de qualidade dos dados antes da análise. Não foram detetados **valores em falta (missing = 0)** nem **registos duplicados (duplicados = 0)**, garantindo consistência do dataset e reduzindo o risco de enviesamento nas estatísticas e no clustering.

Análise estatística do Dataset



Este dashboard agrega, numa só página, a análise global do dataset: **distribuições** (histogramas), **comparações** (boxplots e barras), **relações entre variáveis** (scatter e heatmap), **clustering** (k=6) e **evolução mensal** do indicador_kpi. Serve para obter uma visão rápida dos padrões gerais antes de filtrar por uma área/segmento específico.

Permite analisar os dados na **totalidade** ou **aplicar filtros para explorar uma área** temática específica, adaptando a análise ao contexto pretendido.

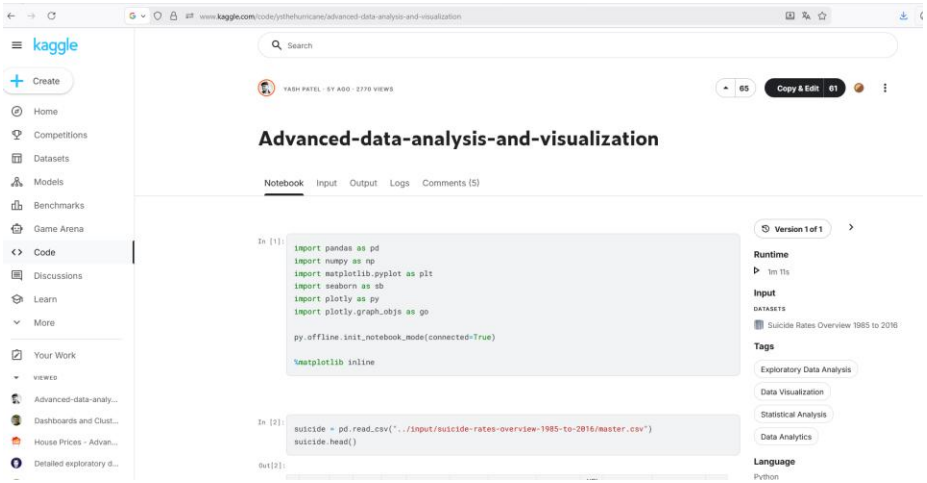
Análise estatística do Dataset



Este dashboard reúne numa única visualização os principais resultados estatísticos: **histogramas**, **teste de normalidade** (QQ-plot), ajuste **Poisson**, modelação **Binomial**, **heatmap** de correlações e **clustering** (k=6). Permite consolidar toda a análise quantitativa de forma integrada e comparável.

Tanto este dashboard como o anterior **podem ser visualizados numa única página HTML** interativa, facilitando a exploração dinâmica dos resultados e a apresentação global do trabalho.

Código



Para a realização deste trabalho, foi utilizado como base o código da fonte acima.

Fonte: Patel, Y. (n.d.). *Advanced data analysis and visualization*. Kaggle. https://www.kaggle.com/code/ysthehurricane/advanced-data-analysis-and-visualization

Código

```python
import pandas as pd

path = "/kaggle/input/datasets/ivoalmeidaramoa/igov-csv/Dataset-iGov.csv"

try:
    df = pd.read_csv(path)
except UnicodeDecodeError:
    df = pd.read_csv(path, encoding="latin1")
except pd.errors.ParserError:
    df = pd.read_csv(path, sep=";")
```

Neste bloco é feito o **carregamento** do ficheiro CSV para um **DataFrame** (df), ficando os dados disponíveis para exploração e análise em Python. A partir daqui, todas as operações (estatísticas, gráficos e modelos) são aplicadas sobre o df.

Código

```
df.head()
df.shape, df.columns.tolist()
df.info()
df.describe(include="all").T
```

As funções df.head(), df.shape, df.columns/df.columns.tolist() e df.info() são usadas para validar rapidamente a estrutura do dataset: primeiras linhas, dimensão (linhas/colunas), nomes das variáveis e tipos de dados. Isto garante que o dataset foi importado corretamente antes de avançar para análise estatística.

A função **df.describe()** gera um **resumo** automático das variáveis numéricas (média, desvio padrão, mínimos/máximos e quartis). Serve como ponto de partida para identificar dispersão, extremos e possíveis inconsistências.

Código

```python
#Preparação mínima
import pandas as pd
import numpy as np

df["data_registo"] = pd.to_datetime(df["data_registo"], errors="coerce")  # já está YYYY-MM-DD
df["ano"] = df["data_registo"].dt.year
df["mes"] = df["data_registo"].dt.month

num_cols = df.select_dtypes(include="number").columns.tolist()
num_cols = [c for c in num_cols if c not in ["id_registo", "ano", "mes"]]

cat_cols = df.select_dtypes(include="object").columns.tolist()

num_cols, cat_cols
```

Este bloco **converte a coluna data_registo para formato datetime** e cria as variáveis **ano** e **mês** para análises temporais. Em seguida, separa automaticamente as colunas **numéricas** (num_cols) e **categóricas** (cat_cols), excluindo identificadores e campos derivados, garantindo que cada tipo de variável é tratado com as operações adequadas. Serve de base para testes, gráficos e clustering.

Código

```python
#Histogramas
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

n = len(num_cols)
cols = 3
rows = int(np.ceil(n / cols))

plt.figure(figsize=(16, 4*rows))
for i, c in enumerate(num_cols, 1):
    plt.subplot(rows, cols, i)
    sns.histplot(df[c].dropna(), kde=True)
    plt.title(c)

plt.tight_layout()
plt.show()
```

Este bloco gera, de forma automática, um conjunto de histogramas para todas as variáveis numéricas em grelha. Para cada variável, é desenhada a distribuição com **KDE** (curva de densidade), permitindo observar rapidamente concentração de valores, dispersão, assimetria e possíveis outliers.

Código

```python
#Estatísticas
def stats_table(df, cols):
    out = []
    for c in cols:
        s = df[c].dropna()
        m = s.mode()
        out.append({
            "variavel": c,
            "n": int(s.count()),
            "min": float(s.min()),
            "q1": float(s.quantile(0.25)),
            "mediana": float(s.median()),
            "media": float(s.mean()),
            "q3": float(s.quantile(0.75)),
            "max": float(s.max()),
            "moda": float(m.iloc[0]) if len(m) else np.nan,
            "desvio_padrao": float(s.std(ddof=1)),
        })
    return pd.DataFrame(out).set_index("variavel")

stats = stats_table(df, num_cols)
stats
```

Cálculo explícito das **estatísticas de 1.ºe 2.º nível** exigidas.

Código

```python
#Normalidade (hist + QQ-plot + Shapiro)

from scipy import stats as spstats

x = df["indicador_kpi"].dropna()

plt.figure(figsize=(6,4))
sns.histplot(x, kde=True)
plt.title("Distribuição (hist + KDE): indicador_kpi")
plt.show()

plt.figure(figsize=(5,5))
spstats.probplot(x, dist="norm", plot=plt)
plt.title("QQ-plot: indicador_kpi vs Normal")
plt.show()

x_test = x.sample(150, random_state=42) if len(x) > 150 else x
spstats.shapiro(x_test)
```

Validação de normalidade com **QQ-plot** e **Shapiro-Wilk** para suportar decisões estatísticas.

Código

```python
#Binomial
threshold = 85
success = (df["taxa_resolucao"] >= threshold).astype(int)

success.value_counts(), success.mean()
```

```python
by_month_success = df.groupby("mes")["taxa_resolucao"].apply(lambda s: (s >= threshold).sum())

plt.figure(figsize=(7,4))
plt.bar(by_month_success.index.astype(str), by_month_success.values)
plt.title(f"Sucessos por mês (taxa_resolucao >= {threshold}) [Binomial]")
plt.xlabel("mês")
plt.ylabel("nº sucessos")
plt.show()
```

Modelação Binomial com **definição de sucesso**, **estimação de p** e **intervalo de confiança.**

Código

```python
#Poisson

from scipy import stats as spstats

x = df["erros_tecnicos"].dropna()
lam = x.mean()

plt.figure(figsize=(6,4))
sns.histplot(x, discrete=True)
plt.title(f"Erros técnicos (hist). Média (λ)={lam:.2f}")
plt.show()

values = np.arange(int(x.min()), int(x.max()) + 1)
pmf = spstats.poisson.pmf(values, mu=lam)
pmf = pmf / pmf.sum()

obs = x.value_counts().sort_index()
obs = obs.reindex(values, fill_value=0) / len(x)

plt.figure(figsize=(7,4))
plt.plot(values, obs.values, marker="o", label="Observado")
plt.plot(values, pmf, marker="x", label="Poisson ajustada")
plt.title("Observado vs Poisson(λ)")
plt.xlabel("erros_tecnicos")
plt.ylabel("probabilidade")
plt.legend()
plt.show()
```

Modelação Poisson para **contagens** e **verificação** de **sobredispersão (var > mean).**

Código

```python
#t-Student
from scipy import stats as spstats

x = df["indicador_kpi"].dropna()
n = len(x)
mean = x.mean()
std = x.std(ddof=1)
alpha = 0.05

tcrit = spstats.t.ppf(1 - alpha/2, df=n-1)
margin = tcrit * std / np.sqrt(n)

(mean, mean - margin, mean + margin)
```

Intervalo de confiança t-Student para a **média quando σ populacional é desconhecido.**

Código

```
#Clustering

from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score
from sklearn.decomposition import PCA

X = df[num_cols].dropna()
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

scores = {}
for k in range(2, 11):
    km = KMeans(n_clusters=k, random_state=42, n_init="auto")
    labels = km.fit_predict(X_scaled)
    scores[k] = silhouette_score(X_scaled, labels)

scores
```

```
plt.figure(figsize=(7,4))
plt.plot(list(scores.keys()), list(scores.values()), marker="o")
plt.title("Escolha de k (Silhouette)")
plt.xlabel("k")
plt.ylabel("silhouette")
plt.show()

best_k = max(scores, key=scores.get)
best_k
```

Neste bloco, os dados numéricos são normalizados com **StandardScaler** e é executado **K-Means** para vários valores de *k*. Para cada *k* calcula-se o **Silhouette Score**, que mede a qualidade da separação dos clusters (quanto maior, melhor). O *k* com melhor valor de silhouette é selecionado como **best_k**, justificando a escolha do número de clusters.

Código

```
km = KMeans(n_clusters=best_k, random_state=42, n_init="auto")
labels = km.fit_predict(X_scaled)

pca = PCA(n_components=2, random_state=42)
X2 = pca.fit_transform(X_scaled)

plt.figure(figsize=(7,5))
plt.scatter(X2[:,0], X2[:,1], c=labels, s=35)
plt.title(f"PCA 2D com clusters (k={best_k})")
plt.xlabel("PC1")
plt.ylabel("PC2")
plt.show()
```

Após fixar o **best_k**, o K-Means é aplicado para obter as labels dos clusters. De seguida, usa-se **PCA** para reduzir as variáveis a 2 dimensões e representar os registos num plano 2D. Este gráfico permite visualizar a distribuição e eventual sobreposição dos clusters, servindo como validação visual da segmentação obtida.

Código

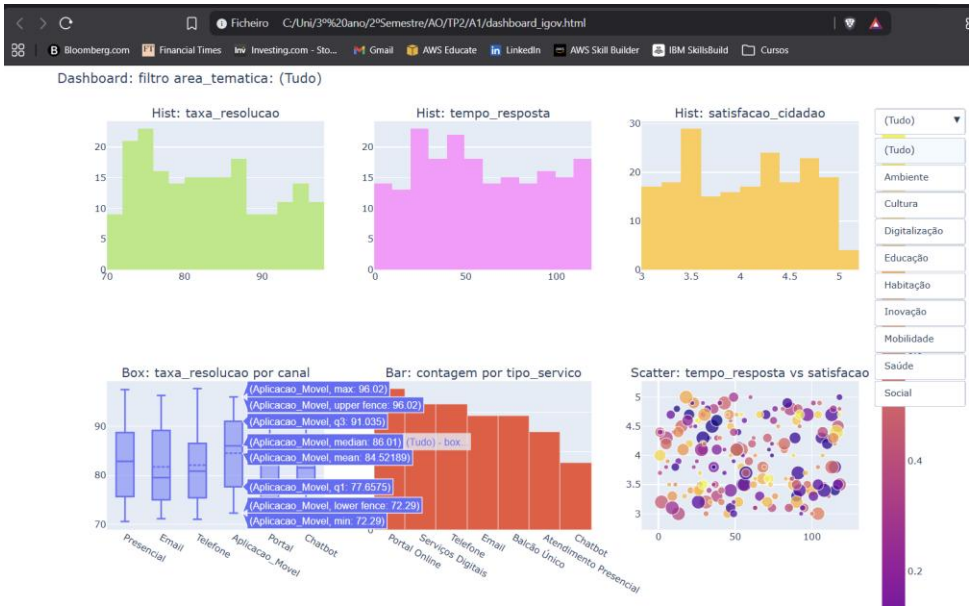
```
import plotly.io as pio

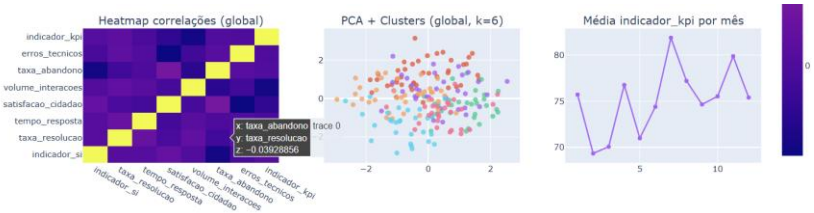
out_path = "/kaggle/working/dashboard_igov.html"
pio.write_html(fig, file=out_path, full_html=True, include_plotlyjs="cdn", auto_open=False)

out_path
```

Neste bloco é feita a **exportação do dashboard** interativo para um ficheiro **HTML**, utilizando **plotly.io** e **write_html.** O ficheiro gerado (dashboard_igov.html) permite visualizar todos os gráficos numa única página, de forma interativa e independente do notebook, facilitando a apresentação e partilha dos resultados.

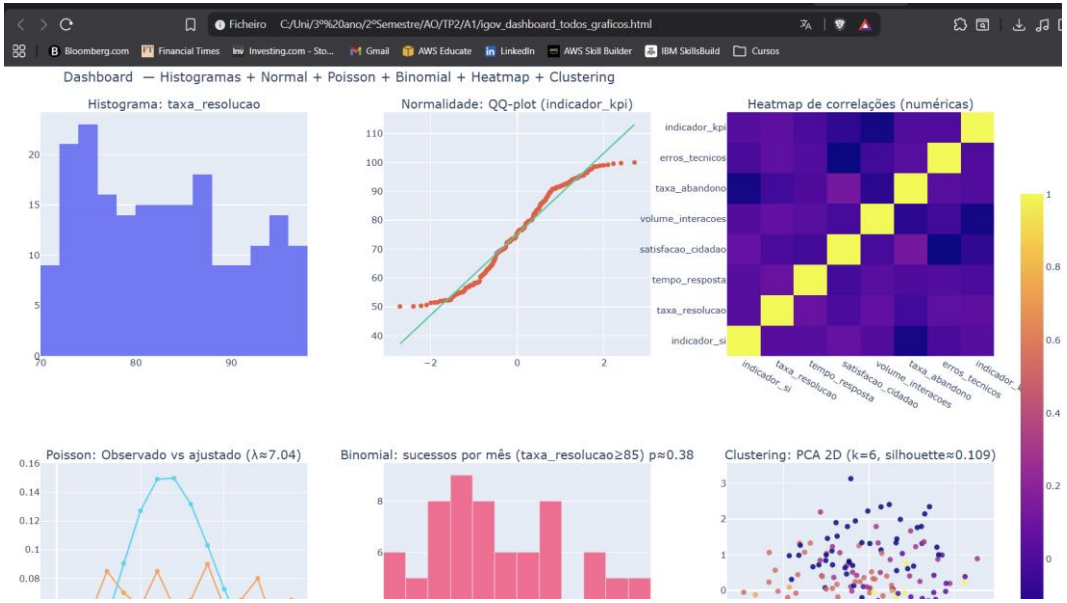
Execução das Scripts com adaptação do código





Este dashboard interativo integra os principais resultados estatísticos numa única página, incluindo distribuições, comparações por canal, correlações, clustering e evolução temporal. Através do **dropdown "area_tematica"**, é possível visualizar **todos os dados (global)** ou analisar **uma área específica**, permitindo adaptar a exploração ao contexto pretendido. Além disso, ao **passar o rato sobre os gráficos**, surgem informações detalhadas, facilitando uma leitura precisa e dinâmica dos resultados.

Execução das Scripts com adaptação do código



Este dashboard consolida, numa única visualização, os **histogramas**, teste de **normalidade** (QQ-plot), ajuste **Poisson**, modelação **Binomial**, **heatmap** de correlações e **clustering** com PCA. Permite ter uma visão integrada da análise estatística e da segmentação dos dados. Tal como no anterior, é possível **interagir com os gráficos** e, ao **passar o cursor sobre os pontos ou barras**, visualizar os valores exatos e estatísticas associadas, tornando a exploração mais intuitiva e informativa.

Conclusão

A análise permitiu **caracterizar a amostra e compreender o comportamento das métricas principais através de estatística descritiva e visualizações**. Os testes e gráficos indicaram que **várias variáveis não seguem normalidade**, e a modelação **Poisson para contagens mostrou limitações quando há sobredispersão**. A abordagem **binomial quantificou a taxa de "sucesso" e respetiva incerteza**, enquanto o **clustering identificou grupos com perfis distintos**, embora com separação limitada. Os dashboards agregaram os resultados numa visão única, facilitando a interpretação e a comunicação das conclusões.

Referências

- **DataSet:** Ficheiro disponibilizado pelo docente na plataforma Moodle

- **Código Exemplo:** Patel, Y. (n.d.). *Advanced data analysis and visualization*. Kaggle. https://www.kaggle.com/code/ysthehurricane/advanced-data-analysis-and-visualization

o teu • de partida



www.ipvc.pt